



# Tecnológico de Monterrey

---

**Inteligencia artificial avanzada para la ciencia de datos**

**Análisis y Reporte sobre el Desempeño del Modelo**

Sergio González Vargas

A01745446

12 de agosto 2023

Instituto Tecnológico y de Estudios Superiores de Monterrey.  
Campus Estado de México.

# Informe de Evaluación y Mejora de Modelo de Clasificación

## Informe de Evaluación y Mejora de Modelo de Clasificación

### Objetivo

El propósito de este informe es evaluar y mejorar el rendimiento de un modelo de clasificación desarrollado utilizando el conjunto de datos "hotel\_bookings\_completo.csv". Se presenta una justificación para la elección de este dataset y se describen diversas evaluaciones y mejoras en el modelo para demostrar su capacidad de generalización. Además, se analiza el sesgo, la varianza y el nivel de ajuste del modelo, y se aplican tres técnicas de mejora con el objetivo de aumentar su desempeño.

### Justificación del Dataset

El dataset seleccionado se eligió cuidadosamente debido a su idoneidad para aplicar algoritmos de Machine Learning y demostrar la capacidad de generalización de un modelo. Las razones para su elección son las siguientes:

1. Cantidad de Datos Adecuada: El conjunto de datos cuenta con un número suficiente de registros, lo que es fundamental para entrenar modelos de Machine Learning efectivos sin caer en el sobreajuste.
2. Diversidad de Características: El dataset incluye una variedad de características relevantes para el problema de predecir si una reserva de hotel será cancelada o no. Esto permite que el modelo tenga en cuenta múltiples aspectos de una reserva, mejorando su capacidad de generalización.
3. Variable Objetivo Balanceada: La variable objetivo, que indica si una reserva fue cancelada o no, está relativamente balanceada en el dataset. Esto evita desequilibrios en las predicciones y garantiza que el modelo se evalúe de manera justa.

### Evaluación del Modelo

Para evaluar el modelo de clasificación, se dividió el dataset en conjuntos de entrenamiento, validación y prueba. Se utilizaron métricas de evaluación, como la precisión (accuracy), la precisión ponderada, el recall y el F1-score, para medir el desempeño del modelo en cada conjunto.

### Separación de Conjuntos de Datos

El conjunto de datos se dividió en tres partes:

- Conjunto de Entrenamiento (Train): Este conjunto representa el 80% del dataset original y se utiliza para entrenar el modelo.

- Conjunto de Validación (Validation): Comprende el 10% del dataset original y se emplea para ajustar los hiperparámetros del modelo.

- Conjunto de Prueba (Test): Constituye el 10% restante del dataset original y se utiliza para evaluar el rendimiento final del modelo.

## **Sesgo y Varianza**

Se realizó un diagnóstico de sesgo y varianza para evaluar el desempeño del modelo. Este análisis se basó en comparaciones de la precisión en los conjuntos de entrenamiento, validación y prueba para medir el grado de sesgo y varianza.

- Sesgo (Bias): Se evaluó mediante la comparación de la precisión en los conjuntos de entrenamiento, validación y prueba. Un sesgo bajo se refleja en una alta precisión en el conjunto de entrenamiento y validación.

- Varianza: Se analizó también mediante la comparación de la precisión en los conjuntos de entrenamiento y validación. Una varianza alta se manifiesta en una diferencia significativa entre la precisión en estos conjuntos.

## **Nivel de Ajuste del Modelo**

Se evaluó el nivel de ajuste del modelo mediante gráficas comparativas de la precisión en los conjuntos de entrenamiento, validación y prueba. Los resultados se interpretaron de la siguiente manera:

- Underfitting: Se identifica cuando la precisión en todos los conjuntos es baja, lo que indica que el modelo es demasiado simple para capturar la complejidad de los datos.

- Ajuste Adecuado (Fit): Se logra cuando el modelo muestra una precisión equilibrada en los conjuntos de entrenamiento y prueba.

- Overfitting: Se evidencia cuando la precisión en el conjunto de entrenamiento es alta, pero en el conjunto de prueba es significativamente más baja.

## **Técnicas de Mejora del Modelo**

Se aplicaron tres técnicas de mejora para aumentar el desempeño del modelo de clasificación:

### **1. Técnica 1: Codificación One-Hot**

- Se implementó una codificación one-hot después de una codificación de variables categóricas estándar.

- Se compararon los resultados antes y después de la codificación one-hot para evaluar su efecto en el desempeño del modelo.

### **2. Técnica 2: Ajuste de Hiperparámetros**

- Se realizó una búsqueda de cuadrícula para encontrar los mejores hiperparámetros del modelo.
- Se evaluó el rendimiento del modelo antes y después de realizar los ajustes de hiperparámetros.

### **3. Técnica 3: Evaluación y Ajuste Adicional**

- Se llevó a cabo una evaluación detallada del modelo, considerando diversas métricas de evaluación.
- Se exploraron posibles mejoras adicionales basadas en el análisis de las métricas.

### **Resultados y Conclusiones**

El análisis de sesgo, varianza y nivel de ajuste del modelo indicó que el modelo tenía un buen ajuste inicial en el conjunto de entrenamiento y una varianza moderada. Sin embargo, se observó un cierto grado de sobreajuste.

Las técnicas de mejora proporcionaron resultados prometedores. La codificación one-hot mejoró la capacidad del modelo para manejar características categóricas, el ajuste de hiperparámetros permitió encontrar una configuración más óptima y la evaluación detallada abrió oportunidades para mejoras adicionales.

En resumen, el dataset seleccionado se adaptó adecuadamente al algoritmo de ML, y se demostró que el modelo es capaz de generalizar. Se aplicaron técnicas de mejora que mostraron un impacto positivo en el desempeño del modelo. Este informe proporciona una visión integral de la evaluación y mejora del modelo de clasificación.